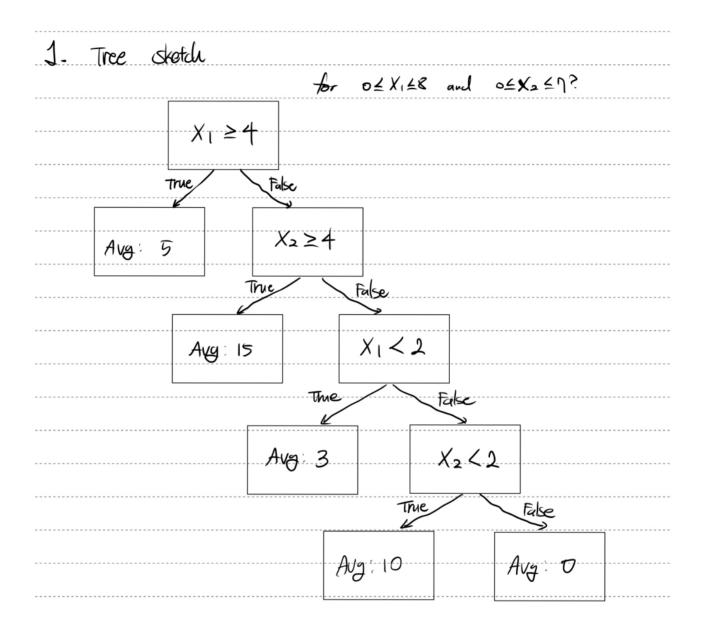
```
In [1]: import numpy as np
   import pandas as pd
   import matplotlib.pyplot as plt
   import seaborn as sns
   from warnings import filterwarnings

filterwarnings('ignore')
```

## 1번



### 2번

다음과 같은 자료,  $X < c, X \geq c$  분할 기준, 왼쪽 오른쪽 마디 구분

```
In [2]: X = np.array([1, 3, 3, 4, 5, 5, 6, 6, 7, 8, 9])
Y = np.array([0, 0, 1, 0, 0, 1, 1, 1, 1])
test = np.vstack([X, Y]).T
```

```
In [3]: tmp = pd.DataFrame(data=[X,Y], index=['X', 'Y']).T
tmp['c=5'] = np.where(np.where(tmp['X']<5, 0, 1) - tmp['Y'] == 0, True, None)</pre>
      tmp['c=7'] = np.where(np.where(tmp['X']<7, 0, 1) - tmp['Y'] == 0, True, None)
Out[3]:
         X Y c=5
                  c=7
              True
        0 1
           0
                  True
        1 3 0 True
                  True
        2 3 1 None None
        3 4 0 True
                  True
        4 5 0 None
                  True
        5 5 1 True None
        6 6 0 None
                  True
        7 6 1 True None
           1
              True
                  True
        9 8 1 True
                  True
       10 9 1 True
                 True
In [4]: '''부모마디의 지니 불순도'''
      gini_imp
Out[4]: 0.4958677685950414
In [5]: '''c=5, gini'''
      gini_1 = 1 - (tmp['c=5'].iloc[:4].count()/len(tmp.iloc[:4]))**2
               - (tmp['c=5'].iloc[:4].isnull().sum()/len(tmp.iloc[:4]))**2
      gini_2 = 1 - (tmp['c=5'].iloc[4:].count()/len(tmp.iloc[4:]))**2\
               - (tmp['c=5'].iloc[4:].isnull().sum()/len(tmp.iloc[4:]))**2
      gini_1, gini_2
      print(f'Gini Impurity when c=5 : {np.round(gini_impurity,4)}')
      print(f'Gini Impurity Improvement : {np.round(gini_imp - gini_impurity, 4)}')
      Gini Impurity when c=5 : 0.3961
      Gini Impurity Improvement: 0.0998
In [6]: '''c=7, gini'''
      gini_4 = 1 - (tmp['c=7'].iloc[8:].count()/len(tmp.iloc[8:]))**2\
                - (tmp['c=7'].iloc[8:].isnull().sum()/len(tmp.iloc[8:]))**2
      gini 3, gini 4
      print(f'Gini Impurity when c=7 : {np.round(gini_impurity_2,4)}')
      print(f'Gini Impurity Improvement : {np.round(gini_imp - gini_impurity_2, 4)}')
      Gini Impurity when c=7: 0.3409
      Gini Impurity Improvement: 0.155
      따라서 c가 7일 때, 지니 불순도가 더 개선된다.
      3번
      Churn_Modelling.csv
In [7]: raw_df = pd.read_csv('./Data/Churn_Modelling.csv', index_col=0)
Y = raw df['Exited']
      X['Gender'] = np.where(X['Gender'] == 'Male', 0, 1).copy()
In [9]: Y.value_counts()
Out[9]: 0
          2037
      Name: Exited, dtype: int64
```

```
In [10]: from sklearn.model_selection import train_test_split
         X_train, X_val, y_train, y_val = train_test_split(X, Y, train_size=0.7, random_state=100, shuffle=True)
         X_train.shape, X_val.shape, y_train.shape, y_val.shape
```

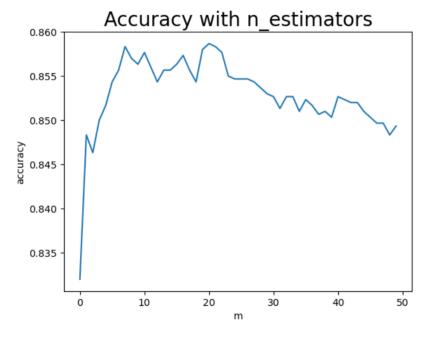
```
Out[10]: ((7000, 9), (3000, 9), (7000,), (3000,))
```

#### 3-(2) Adaboost

```
In [11]: from sklearn.ensemble import AdaBoostClassifier
         from sklearn.tree import DecisionTreeClassifier
         from sklearn.metrics import accuracy score
         ada = AdaBoostClassifier(DecisionTreeClassifier(max_depth=2),\
                                  n estimators=50, random state=100,
                                  algorithm='SAMME.R')
         ada.fit(X_train, y_train)
         init_reg = accuracy_score(y_val, ada.predict(X_val))
         acc = [accuracy_score(y_val, y_valpred) for y_valpred in ada.staged_predict(X_val)]
         bst n estimators = np.argmax(acc)
         print(bst_n_estimators, init_reg)
```

20 0.8493333333333334

```
In [12]: import matplotlib.pyplot as plt
         plt.plot(acc)
         plt.xlabel('m')
         plt.ylabel('accuracy')
         plt.title('Accuracy with n_estimators', size=20)
         plt.show()
```



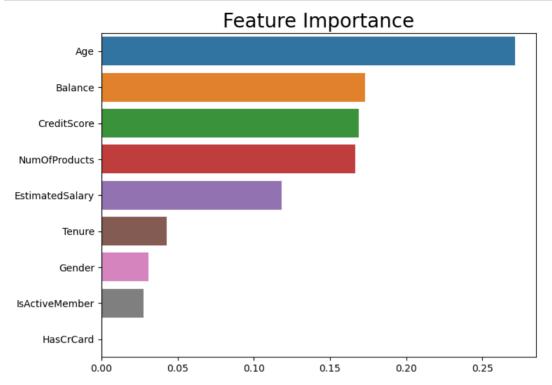
```
In [13]: ada_best = AdaBoostClassifier(DecisionTreeClassifier(max_depth=2),\
                                  n_estimators=bst_n_estimators, random_state=2,
                                  algorithm='SAMME.R')
         ada_best.fit(X_train, y_train)
         accuracy_score(y_val, ada_best.predict(X_val))
```

Out[13]: 0.858

#### 3-(3) Feature Importance

```
In [14]: import seaborn as sns

imp_values = pd.Series(ada_best.feature_importances_, index=X_train.columns)
imp_values = imp_values.sort_values(ascending=False)
plt.figure( figsize=(8,6) )
plt.title('Feature Importance', size=20)
sns.barplot(x=imp_values, y=imp_values.index)
plt.show()
```



중요한 변수는, 순서대로, 'AGE', 'Balance', 'CreditScore' 이다

### 4번

```
답) 1번 2번
```

배깅은 일부러 왜곡된 데이터를 만들고, (부트스트랩) 노이즈가 다른 분포를 가지는 학습기들을 만들어 결합함으로써 변동으로 인한 영향을 줄일 수 있다.

### 5번

#### **PCA**

$$\mathrm{COV}_{matrix} = P \Sigma P^T$$

P는 고유벡터(고유값 순으로 정렬된 것),  $\Sigma$  는 diagonal한 고유값 행렬

```
In [16]: '''주성분'''
         print(np.round(eig_vector[:,0],3),
                np.round(eig_vector[:,1],3),
                np.round(eig_vector[:,2],3), sep='\n')
         [0.065 0.504 0.861]
         [-0.535 -0.711 0.456]
         [-0.842 0.491 -0.224]
         PCA를 통해 구한 주성분
         주성분_1 = +0.065x_1 + 0.504x_2 + 0.861x_3
         주성분_2 = -0.535x_1 - 0.711x_2 + 0.456x_3
         주성분<sub>3</sub> = -0.842x_1 + 0.491x_2 - 0.224x_3
In [17]: '''Explained Variance Ratio'''
         explained variance = []
         for i in range(len(eig_value)):
             explained_variance.append(eig_value[i] / np.sum(eig_value))
         print(np.round(explained_variance,3))
          [0.673 0.229 0.098]
         주성분 별 Explained Ratio
         주성분_1 = 0.673 = 67.3\%
         주성분_2 = 0.229 = 22.9\%
         주성분_3 = 0.098 = 9.80\%
```

### 6번

상관행렬을 이용한 주성분 분석 : 표준화 변수를 이용한 공분산 행렬을 주성분 분석에 활용

#### 6-(1): 첫 두개의 주성분 산출 식

### 6-(2)

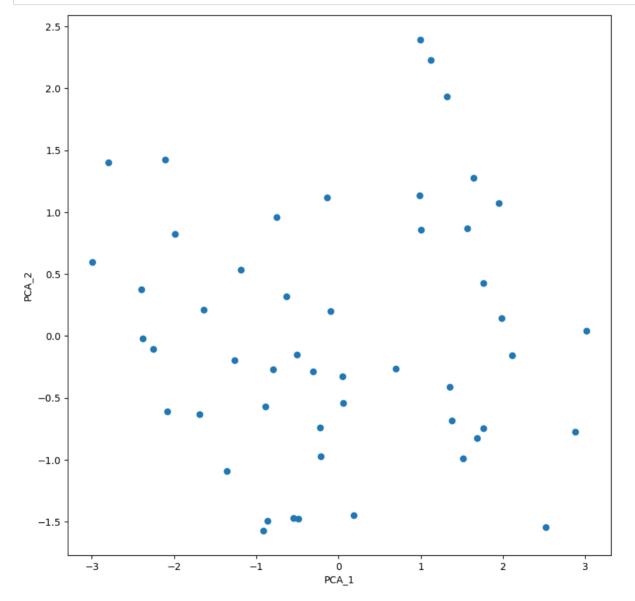
첫 두개의 주성분은, 특성변수의 전체 변동 중 약 86.75%를 설명하고 있다. (62% & 24.74%)

```
Out[21]:
```

	pca1	pca2	pca3	pca4
0	0.985566	1.133392	-0.444269	0.156267
1	1.950138	1.073213	2.040003	-0.438583
2	1.763164	-0.745957	0.054781	-0.834653
3	-0.141420	1.119797	0.114574	-0.182811
4	2 523980	-1 542934	0.598557	-0.341996

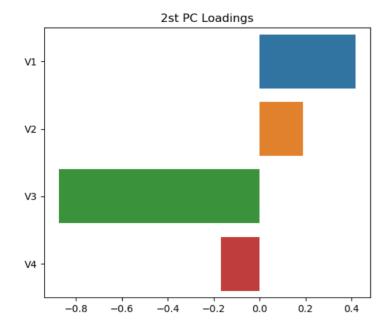
# 6-(3) 첫 두개의 주성분 점수를 산점도를 이용해 시각화

```
In [22]: plt.figure(figsize=(10, 10))
    plt.scatter(df_pca[:,0], df_pca[:,1])
    plt.xlabel('PCA_1')
    plt.ylabel('PCA_2')
    plt.show()
```



```
In [23]: plt.figure(figsize=(6,5))
    plt.title('2st PC Loadings')
    sns.barplot(x=pca.components_[1], y=df.columns)
```

Out[23]: <AxesSubplot:title={'center':'2st PC Loadings'}>



두번째 주성분은 첫번째 주성분 다음으로 데이터의 변동이 큰 주성분이며, V3의 변수의 변동을 음의 방향으로 크게 반영하는 주성분이다. 첫번째 주성분과 비교했을 때, 각 특성변수 중, V3의 영향이 두드러지며, 음의 방향으로 이 V3 특성을 반영하고 있다.